

Multi-turn Dialogue Evaluation System



复杂指令下的多轮对话评测系统

1 系统概述

1.1 背景与目标

在电话外呼场景中，负责自动外呼的 Bot 不仅需要理解任务指令，还需要在多轮对话中持续推进主流程、回答用户问题、处理拒绝和边界问题，并在安全风险场景下及时终止通话。Bot 外呼的难点不在于“能不能回答一句话”，而在于它能不能在连续对话中稳定执行复杂指令。一个真实外呼任务往往包含开场白、身份说明、主流程推进、用户追问、用户拒绝、边界问题、固定话术和收尾规则。只看单轮回答，很难判断 Bot 是否真的完成了任务；只靠人工抽查，也很难覆盖足够多的用户反应和对话路径。因此，我们需要针对外呼 Bot 设计一套可解释、可量化的全自动评测系统。

基于以上背景，本项目提出 **CallEval**：一个面向外呼任务的复杂指令遵循评测系统，目标就是把这种复杂评估变成自动化流程。系统先理解一份任务说明，把任务说明拆解成可测试的规则和路径，通过自动生成测试场景、模拟用户与被测 Bot 对话，并结合规则层检测和 LLM Judge 评分，输出可解释的多维评测报告。本文后续章节会分层展开，但整体上可以先把整个过程理解为一¹条流水线：任务说明进入系统，经过场景构建、对话模拟和评估报告三个阶段，最终变成可查看、可追溯、可复盘的评测结果。

总的来说，本系统希望做到三件事：第一，尽可能系统地覆盖复杂任务中的主流程、分支和异常情况；第二，用稳定的规则检查降低评测的随意性；第三，用 LLM Judge 补充规则难以覆盖的语义质量判断。

1.2 三层架构总览

当前系统分成三层：场景构建层、对话模拟层和评估报告层。场景构建层负责理解任务，找出应该测试哪些流程和分支；对话模拟层负责让模拟用户和被测 Bot 进行多轮交互，生成完整对话记录；评估报告层负责把对话记录转化为分数、扣分原因和能力画像。前端工作台负责把这三层的结果展示出来，便于查看规则、对话和评分。




图 1.1 系统整体架构设计

场景构建层负责把原始任务说明转化为可执行的测试设计。系统首先解析指令中的流程步骤、约束条件和 FAQ 信息，再整理出规则之间的关系，形成规则知识图谱；随后根据主流程、分支、挽留、探针等结构枚举测试路径，并将路径与合适的用户类型进行匹配，生成后续可运行的执行计划。

对话模拟层接收这些路径和执行计划后，组织模拟用户、对话状态追踪和被测 Bot 进行多轮循环交互：模拟用户按照人设、目标状态机和路径驱动产生回应，被测 Bot 根据任务指令、变量和上下文推进任务，中间的状态追踪模块持续记录违规、路径覆盖率、终止原因和完整消息记录。

评估报告层则基于这些对话轨迹进行评分，先由规则评分模块检查硬违规、流程覆盖、F4 要点遗漏和重复回复等可自动判断的问题，再由 LLM 评委依据六个维度对对话质量进行语义评价，最后由汇总计分模块按照规则分 40% 与 LLM 分 60% 的权重生成总分、等级和可解释评测报告。

总体而言，整个架构的核心逻辑是：第一层保证“测什么”有依据，第二层保证“怎么测”有真实多轮交互，第三层保证“如何判分”既有规则稳定性，也有语义解释能力。

1.3 完整执行流程

一次完整评测从选择或上传任务数据开始。系统先读取任务说明，整理出任务角色、开场白、流程步骤、知识点、边界规则和话术要求；随后生成需要覆盖的测试路径，并描述各路径对应的激活规则与步骤；接着系统逐条运行对话，让用户模拟器和被测 Bot 围绕目标路径进行多轮交互；最后，系统根据对话结果进行规则评分和 LLM-as-Judge 评分，并汇总成报告。具体流程可以概括为以下八步：

- a. 准备任务数据：用户选择内置数据集，或上传新的任务文件。
- b. 解析任务说明：系统识别角色、目标、流程、知识点、变量和约束。
- c. 构建测试路径：系统根据任务结构生成主流程、FAQ、拒绝、越界等路径。
- d. 生成执行计划：系统将路径与不同风格的用户类型进行组合，并计算最大对话轮数。
- e. 运行模拟对话：Bot 先发起外呼，模拟用户按路径和上下文内容回应。
- f. 记录运行证据：系统保存每轮话术、状态变化、流程覆盖和违规信息。
- g. 计算评测分数：规则评分和大模型评分共同形成总分。
- h. 展示评测报告：前端展示总分、维度分、对话记录、违规和改进建议。

整个流程强调“可追溯”。如果某个场景分数低，用户可以从报告一路回看：这条计划测的是什么路径、用户是什么类型、对话在哪里偏离、规则扣了哪些分、大模型为什么给出较低评价。




图 1.2 端到端执行流程图

2 相关概念

本章解释系统里几个容易混淆的概念。简单来说，任务指令告诉系统 Bot 应该执行什么；规则和状态机帮助系统判断对话走向；路径和执行计划决定本次测试要测哪一种情况；用户人设决定模拟用户采用的说话方式和语气；评测指标决定最终的给分标准。

2.1 任务指令与结构化任务约束

任务指令是一份自然语言说明，里面可能包含外呼身份、任务目标、开场白、流程步骤、FAQ、禁止事项、边界处理和变量信息。人读这份说明时可以凭理解执行，但机器评测需要更清晰的结构。因此，系统首先会把这份说明整理成结构化内容，让后续模块知道哪些是流程要求，哪些是知识要求，哪些是话术约束，哪些是边界规则。

结构化约束不是为了改变任务，而是为了让任务可测试。例如，“必须先确认身份再说明事项”会成为流程约束；“用户问配送时间时要回答具体时间”会成为知识约束；“不能承诺职责之外的事项”会成为边界约束；“每轮回复尽量简短自然”会成为话术约束。把这些内容拆解清楚，系统便能在对话结束后判断 Bot 是否真的遵守了任务。

换言之，结构化约束是原始任务说明和自动评测之间的桥梁。它既保留任务原意，又让系统能够生成路径、驱动对话和解释扣分。

2.2 规则图谱

规则图谱（Rule Knowledge Graph, Rule KG）用于表示任务说明中的规则元素及其关系，它把主流程、条件分支、FAQ、边界规则、挽留逻辑和全局话术要求连接起

来，使系统知道哪些规则是顺序执行的，哪些规则会在用户追问时触发，哪些规则是全程都要遵守的。

2.3 有限状态机

有限状态机（FSM）用于追踪对话是否按照任务流程推进，可以把它理解为系统给对话设置的一条“进度轨道”。它记录当前处于身份确认、任务介绍、主流程推进、FAQ 处理、边界处理、挽留、结束等中的哪一种状态，下一步应该往哪里走，以及用户的不同反应会把对话带到哪个分支。与规则图谱关注“有哪些规则”不同，FSM 更关注“对话此刻走到哪里，以及下一步应该如何转移”。

在模拟过程中，状态机帮助系统判断 Bot 是否按路径推进。例如，如果当前应该完成 F2 步骤，但 Bot 跳过了它直接收尾，系统就能发现流程覆盖不足。如果用户提出 FAQ，状态机会让对话进入 FAQ 分支；FAQ 处理后，系统再看是否回到原来的主流程。这样，系统不会只看 Bot 说得是否流畅，也会看它有没有按任务要求完成关键步骤。状态机也是评分证据的一部分。评估报告中的流程覆盖率、未覆盖节点和终止原因，都与状态机记录有关。

2.4 路径、场景与人设

路径（Path）表示一次测试想覆盖的对话路线。它可能是一条主流程路径，也可能包含用户追问、拒绝、跑题或边界问题。路径本身只是“要测什么”，还不能直接运行；系统还需要把路径和用户类型、变量值、最大轮数等信息结合起来，形成执行计划。

场景（Scenario）是路径的自然语言化表达。它是完整、可读、能被人理解的测试目标描述，不是只展示“F1、C2、FAQ”之类的内部标签。例如，一个场景可以描述为“用户在电话中先确认自己身份，但对配送安排提出追问，用于检验 Bot 是否能先回答 FAQ 再回到主流程”。这种表达能帮助前端用户理解这条测试到底在测什么。

用户人设（Persona）描述的是模拟用户如何说话。当前系统中，用户表达风格类型包括配合型、急躁型、抵抗型、质疑型、懵懂型和跑题型。配合型通常愿意推进任务，急躁型更关注效率，抵抗型会带有保留或不情愿，质疑型会追问规则依据，懵懂型容易听不懂，跑题型会提出与任务边界不完全相关的问题。

表 2.1 不同人设的具体描述

用户人设	具体描述
配合型	愿意配合、目标导向
懵懂型	听不太懂、容易困惑
急躁型	着急、赶时间、嫌啰嗦
质疑型	谨慎、爱追问依据与后果
抵触型	防备、质疑、不情愿
跑题型	容易跑题、注意力分散

2.5 评测指标

当前评分由两部分组成：规则评分和大模型评分。规则评分负责检查比较明确、可自动识别的问题，例如流程覆盖不足、硬边界违规、开场白不匹配、回复重复、关键步骤遗漏等。大模型评分负责判断更偏语义和质量的问题，例如回答是否自然、是否真正遵循流程、知识是否准确、边界处理是否得体。

总分当前采用规则 40% + 大模型 60% 的方式聚合。大模型评分包含六个维度：流程遵循、话术合规、知识准确、挽留效果、边界处理和自然度。六维权重分别为 25%、20%、20%、15%、10% 和 10%。其中挽留效果不是所有场景都适用，如果用户全程配合、没有拒绝或异议，系统不会机械地因为没有挽留而扣分。

表 2.2 大模型评分维度

维度	权重	含义
流程遵循度	25%	是否完成任务主流程，是否在普通打断后继续推进未完成流程
话术合规度	20%	是否满足字数、语气、禁止表达、明确挂断等话术要求
知识准确度	20%	是否正确回答 FAQ、变量值、合同/产品/费用等知识点
挽留效果	15%	用户犹豫或拒绝时，是否进行合理挽留或安抚
边界处理	10%	超范围问题、优惠券、算法、名额等边界问题是否处理正确
对话自然度	10%	是否像真实电话交流，是否简洁自然、不机械重复

3 场景构建层

场景构建层负责把一份任务说明变成可运行的测试计划。它没有简单地让大模型“随便生成几个场景”，而是先理解任务结构，再整理规则关系，然后生成应该覆盖的路径，最后把路径和用户类型组合成执行计划。这个阶段决定了评测覆盖是否充分，也决定了后续对话是不是围绕正确目标展开。




图 3.1 场景构建层架构

3.1 任务指令结构化解析

任务指令结构化解析的目的，是把原始文本整理成系统能使用的信息。该模块将非结构化任务说明或 Excel 配置解析为六类节点，每类节点有明确的检测属性和图谱关系。系统会识别外呼角色、任务目标、开场白、主流程步骤、FAQ、边界规则、变量和话术约束，基于这些结构化字段生成规则图谱、FSM 和测试场景。解析结果越清晰，后续路径生成和评分就越可靠。

约束类型体系将任务文本中的各类规定按语义归入角色、流程、知识、话术与边界五类约束，并为每类约束指定节点命名规则、来源段落及后续检测方式——流程约束由有限状态机追踪覆盖情况，可量化的话术约束由 Python 表达式自动核验，其余主观维度则路由至 LLM Judge 进行评判。

优先级与硬约束判定规则通过识别原文语气词将约束强度映射为五个优先级：含必须、严禁等绝对性语气的条目标记为 is_hard = True、Priority 1，违反时施以最高扣分；含需要应该等常规要求的条目依次降级；纯背景说明性内容则置于最低优先级，通常不参与自动扣分。

两套标准协同作用，使系统在完成文本解析后，对每条约束均具备明确的类型归属、检测路径和违规代价，从而为 Layer 2 对话仿真提供结构化的执行依据，并为 Layer 3 评分引擎提供统一的规则输入。指令和规则解析的具体方式如下表 3.1、表 3.2 所示。

表 3.1 指令解析表

类型	节点 ID	来源	检测方式
角色约束 Role	R1, R2 ...	# Role 段	LLM Judge 评分（身份视角）
流程约束 Flow	F1, F2 ...	# Call Flow 段，按步骤顺序	FSM 状态追踪，完成即通过
知识约束 Knowledge	K1, K2 ...	# Knowledge Points FAQ	关键词/语义/意图匹配触发，内容准确性由变量验证
话术约束 Dialogue	D1, D2 ...	# Constraints 段	measurable=True → Python 表达式自动检测；False → LLM Judge
边界约束 Boundary	B1, B2 ...	# Constraints 中的条件触发项	FSM 异常跳转后触发，检测特定话术是否出现

表 3.2 规则解析表

优先级/is_hard	判断标准与示例
Priority = 1, is_hard = True	指令含"必须"/"严禁"/"不得"，或违反会导致合规风险/错误信息传递。例：超出职责范围时必须使用固定话术
Priority = 2, is_hard = False	指令含"需要"/"应该"/"请"/"要求"。例：每次回复控制在约 30 字以内（"约"说明有弹性）
Priority = 3, is_hard = False	指令含"尽量"/"建议"/"最好"。例：避免重复回复，如需重申请换种方式
Priority = 4, is_hard = False	指令含"可以"/"适当"/"酌情"，或描述性说明无强制语气。例：保持语气随意，像打电话一样自然
Priority = 5, is_hard = False	背景说明性约束，无任何语气词。通常 measurable = False。

3.2 规则图谱构建

规则图谱的核心目标是将人工编写的自然语言指令转化为机器可遍历的有向图结构。在本项目中，它用于支持三件事：第一，枚举有意义的对话路径，覆盖分支、FAQ、越界、拒绝和挽留场景；第二，明确每条路径上会激活哪些规则，为评分提供依据；第三，在前端可视化任务结构，辅助人工审查。




图 3.2 规则知识图谱构建

图谱使用 NetworkX 有向图 (nx.DiGraph) 表示，由四层叠加构成如图 3.2 所示：流程步骤层、流程分支层、约束层和元层。流程步骤层描述任务从开始到结束的基本顺序；流程分支层描述“如果用户怎样，则 Bot 应该怎样”的分支；约束层把流程、知识、边界和话术约束附着到对应节点；元层则记录全程生效的规则，例如不可越界承诺、不可重复话术、必须符合收尾要求等。具体的图谱创建流程如下：

首先，图谱会先创建固定的起止和转移节点，例如 START、END、CLOSING、FAQ_NORMAL、FAQ_OOB、OBJECTION、F3_RETAIN、OBJ_FINAL 等。随后，系统把任务中的主流程步骤依次映射为 F1、F2、F3 这类流程节点，并按顺序连接。如果某个流程步骤存在条件分支，系统会把分支展开为分支节点和操作子步骤节点，使对话必须经过相应分支后再继续推进。具体的节点类型如下表 3.3 所示。

表 3.3 各节点类型及含义

node_type	典型 ID	含义
meta	START、END、 GLOBAL_DIALOGUE、 GLOBAL_BOUNDARY	系统级元节点，对话的起止与全局规则汇总
flow_step	F1、F2、...、Fn	指令 Call Flow 的有序步骤，一步对应一个节点
transition	CLOSING、FAQ_NORMAL、 FAQ_OOB、OBJECTION、 F3_RETAIN、OBJ_FINAL	对话状态转移节点，代表可能发生的场景切换
flow_branch	branch::4::1（或结构化 branch_id）	某步 Fi 下的条件分支，来自指令原文的"若...则..."语句
op_step	op::4::1::1	分支内部的操作子步骤，可附带 pause_s 等属性
constraint	D1、K1、B1、R1 等	一条结构化约束规则
knowledge	knowledge_node_xxx	知识要点节点，来自指令 FAQ 段或 knowledge_nodes

其次，在主流程之外，系统会为每个流程节点添加中断轨。也就是说，用户可以在任意步骤提出拒绝、FAQ 或越界问题。FAQ_NORMAL 通常会在处理完用户问题后回到原流程；FAQ_OOB 通常会被引导至收尾；拒绝和挽留场景则会进入挽留轨 F3_RETAIN，并根据用户是否继续拒绝决定回到流程还是终止。

最后，在生成路径时，考虑到约束节点作为全局约束存在，不将其包括到路径里，而是按类型挂载到相应图节点上。流程约束跟随流程节点生效；知识约束在用户合规追问时触发；边界约束在越界问题场景中强制生效；话术约束则在全程每次 Bot 回复时持续检查。图谱构建完成后，系统还会做确定性静态检测，例如重复话术约束、流程顺序断裂等问题。

3.3 FSM 构建

FSM 根据任务主流程和关键分支生成，用于在对话运行时追踪当前进度。主流程状态负责判断 Bot 是否完成了任务；分支状态负责处理拒绝、FAQ、边界问题和安全风险；终止状态负责记录通话结束原因。

FSM 的设计重点是“站在用户视角驱动对话”。系统会根据当前目标路径判断模拟用户下一步应该做什么：如果当前路径需要测试 FAQ，用户就会在合适位置追问；如果当前路径需要测试拒绝，用户就会表达拒绝或犹豫；如果当前路径是主流程，用户则主要配合推进。同时，它也是评分证据的一部分。报告中的流程覆盖率、未覆盖节点、是否提前终止、是谁挂断电话，都应当能从状态机记录中追溯出来。

表 3.4 FSM 状态类型

状态类型	说明
START	对话开始
TASK_INTRO	bot 进行开场和任务说明
MAIN_FLOW	主流程推进
FAQ_HANDLING	用户提问，bot 先回答再拉回主流程
OBJECTION / RETENTION	用户拒绝、犹豫，需要挽留
BOUNDARY_HANDLING	超范围或边界问题
SAFETY_STOP	用户开车/驾驶/骑车等安全风险，必须结束
CLOSING	bot 明确收束并挂断
END	对话结束

3.4 路径自适应提取

路径生成的核心问题是：面对包含多个 if/else 分支、FAQ、越界和挽留逻辑的复杂任务，如何系统地确定“需要测哪些路径”？传统全排列在分支较多时路径数量爆炸；完全随机则覆盖不可控。因此，当前方案采用自适应结构化覆盖：根据任务图谱特征自动选择路径生成策略，在路径数量上限内最大化有效覆盖。

执行路径生成时，入口函数根据指令模式推断路径的结构。如果图中存在条件分支，系统会进入分支覆盖模式，优先覆盖主分支、替代分支和关键异常分支。如果图中存在挽留节点，系统会在主流程基础上加入挽留变体，例如“拒绝后继续”“拒绝后仍不接受并收尾”等。如果任务结构较简单，系统则采用线性路径，并在必要位置插入 FAQ、越界或探针场景。




图 3.2 路径自适应提取

路径生成主要包含 DFS 策展与结构化覆盖两种模式。

在线性场景下，采用 DFS 策展遍历生成路径，对不符合语义的路径进行剪枝提升效率。首先，在图上深度优先搜索，收集所有可能的中断组合路径作为候选池。其次，按语义模板从候选池中挑选代表性路径，覆盖纯 FAQ、纯 OOB、挽留后继续、FAQ + 挽留后继续、OOB + 挽留后继续等场景模板。最后，将策展结果与主干路径合并，对生成的路径去重，并提取路径语义指纹，两条路径若分支签名和中断模式相同，则视为语义等价，后者被丢弃。这避免了节点序列略有差异但测试意义相同的冗余路径。DFS 自动发现隐路径，保证覆盖完整性并且结合剪枝使路径生成更加灵活高效。

当路径中存在明确分支时，采用结构化覆盖。具体而言，从 START 出发沿图走到 END，遇到分支步骤时按字典选择对应分支，跟随 op 链后 goto 到目标步骤，最终返回完整节点序列。采用三级覆盖策略：第一层覆盖核心分支组合，对指令中存在分支

的流程节点做笛卡尔积网格，每条路径代表一种核心业务决策的组合，确保高优先级分支节点全部出现；第二层覆盖替代分支，补充覆盖那些在主流配合路径下不会触发的边缘分支，使不同分支条件都有机会被测试；第三层用兜底路径覆盖 FAQ、越界、挽留和主流程连续性，确保每个分支节点至少在一条路径中出现。系统还会根据语义键去重，避免多个路径虽然标签不同但实际测试目标重复。分支组合网格用最少的路径让每条分支都被测到至少一次，防止 DFS 遍历造成组合爆炸。

无论何种模式，系统都会在结构化主干路径的基础上叠加三类变体路径，去重后并入路径集合。FAQ 变体在基准路径某步 F_i 之后插入 FAQ_NORMAL 节点，再返回，模拟用户在该步完成后追问的场景。OOB 变体在基准路径某步 F_i 之前插入 FAQ_OOB 节点，模拟用户在该步开始前提出越界问题，路径随即跳转到 CLOSING 结束，测试 Bot 守界并礼貌收束的能力。探针变体在基准路径中插入场景探针节点，专门用于测试对应的特殊场景约束是否被正确处理。

3.5 场景生成

场景生成负责把内部路径变成人能读懂的测试场景。场景由完整的自然语言描述，说明用户会在什么情境下采取什么行为，以及这条场景要检验 Bot 的哪项能力。例如，场景可以写成“用户在确认身份后询问配送时间，Bot 需要先回答合规 FAQ，再回到合同通知主流程并完成收尾”。这样的描述比单独展示节点标签更容易被理解，也更适合前端展示和人工复盘。

4 对话模拟层

对话模拟层负责让系统真正运行起来。系统根据执行计划创建一段电话外呼对话：Bot 先发起开场，模拟用户根据路径目标和表达风格回应，Bot 再根据任务说明和上下文继续推进。整个过程会持续记录消息、用户动作、状态变化、流程覆盖、违规证据和终止原因。这一层的质量直接影响评测可信度，因为评分不是凭空产生的，而是基于这里生成的完整对话轨迹。




图 4.1 对话模拟层架构

4.1 对话运行流程

对话运行采用循环式状态图。初始化时，系统会载入执行计划、任务说明、用户表达风格、目标路径、最大轮数和空消息列表。如果消息列表为空，说明对话尚未开始，此时由被测 Bot 先输出开场白；之后每一轮由用户模拟器产生用户回复，再由被测 Bot 产生回应。

每轮对话后，系统都会更新状态，包括当前消息列表、目标 FSM 进度、已覆盖节点、违规列表、用户类型、Bot 状态、当前轮数、停滞轮数和终止原因。如果 FSM 长时间没有推进，系统会判断是否需要强制让用户回到配合轨道，以免对话无限停留在无意义循环中。

最终，对话层输出的不只是一串消息，还包括流程覆盖率、终止原因、违规列表、用户动作识别、Bot 重复情况和开场白匹配情况。这些信息都会进入评分阶段。

整体而言，对话运行大致包含以下流程：

- a. 系统每次选择一个测试路径，初始化模拟用户与被测 Bot。
- b. 模拟用户根据场景和表达风格生成用户话术；

- c. 被测 Bot 根据任务指令和历史对话生成回复；
- d. 系统记录每轮的用户文本、被测 bot 文本等。

4.2 用户模拟器

用户模拟器的设计目标是，在每轮对话中，基于当前路径位置和用户表达风格，生成一条语义合理、行为可控的用户话语，同时对该话语的动作类型进行检测标注，为 FSM 推进和终止判断提供依据。

a. GoalFSM 路径指针驱动

GoalFSM 是一个沿 Layer1 枚举路径顺序移动的 FSM：持有一条预先规划好的路径（如 [START, F1, F2, FAQ_NORMAL, F3, F3_RETAIN, CLOSING, END]），并根据每轮用户动作把指针向前推进，确保整条对话按预定路径走完。每当用户动作满足当前节点的转移条件，将指针推进到下一节点，并将新节点追加到“已覆盖节点”集合，作为路径覆盖的证据。这种设计保证了仿真对话严格沿着预定义的路径推进，而非自由游走。

b. 路径动作推断

在生成用户话语之前，系统首先根据 GoalFSM 当前节点类型推断出本轮用户应执行的动作，作为 LLM 生成的强约束。具体规则为：当 FSM 处于异议或挽留节点（OBJECTION、F3_RETAIN、OBJ_FINAL）时，推断用户动作为“拒绝”，用于驱动挽留和拒绝路径；处于合规追问节点（FAQ_NORMAL）时推断为“追问”；处于越界问题节点（FAQ_OOB）时推断为“偏题”；处于主干流程步骤节点时推断为“遵从”，配合推进流程。

质疑型用户有一项特殊处理：若当前处于流程步骤节点且本步骤尚未被追问过，即便路径动作为“遵从”，系统也会将其覆盖为可以继续追问，并附带提示"就 Bot 刚说的规则追问一句依据、后果或怎么算"，以提升 FAQ 场景的覆盖深度。

c. 话语生成

调用 LLM 生成用户话语，输入上下文包括：用户人设、推断得到的路径动作及话语提示、完整对话历史、用户历史发言、跨轮积累的已知信息摘要、当前 FSM 状态以及允许的动作集合。这些信息共同约束 LLM 输出，使生成的用户话语在行为上符合路径预期，在措辞上符合用户人设。

d. 动作标签检测

对生成的用户话语，系统执行两阶段动作识别：优先进行关键词匹配，词典命中时直接返回对应动作标签，识别出的动作标签同时用于 FSM 转移和终止条件判断；若无法确定动作标签，则调用 LLM 进行语义分类兜底。对置信度低于阈值的识别结果，在最终报告中提示需要人工复核，这样可以避免用户模拟器说出的话和目标路径不一致却没有被发现。

4.3 被测 Bot

被测 Bot 是评测对象。它的核心职责是：接收完整指令和对话历史，在当前 FSM 状态下生成一条符合规范的回复话语，同时触发 DST 约束检测，将违规证据实时记录到状态中。Bot 节点按以下优先级顺序选择生成策略，高优先级命中后不再执行后续策略。

a. 首轮外呼（Opening Line）

若为首轮且指令包含 opening_line 字段，Bot 直接输出经变量替换后的 Opening Line，不调用 LLM。这确保外呼场景的首句话严格按照指令要求输出，同时记录骑手姓名是否被正确使用。

b. LLM 生成及特殊节点处理

输入包括完整指令文本（作为 System Prompt，含变量替换）、当前步骤说明文本、完整对话历史和用户动作。部分节点有专项处理策略：CLOSING 节点先推断收尾语气，LLM 回复不合格时回退到预定义模板；OBJ_FINAL 节点（最终拒绝关闭）和 FAQ_OOB 节点（越界问题守界）均直接使用模板话术，不调用 LLM，以保证这两类场景下回复的合规性。

c. 重复守卫

每次 Bot 生成回复后，系统通过精确匹配、前缀匹配、主题关键词多次命中等多重策略来检测新回复与近期历史是否语义重复，若重复则从候选集中选择非重复话术替换。系统维护最近 4 条 Bot 话语作为去重窗口，并记录重复次数，供 Layer 3 扣分使用。

d. DST 违规检测

DST 为对话状态追踪，是系统中一个轻量的实时检测模块，主要负责实时约束检查。Bot 回复追加到消息列表后，立即进行实时约束检测。系统检查两类违规：一是话术长度超限，触发时追加类型为“字数超限”的违规记录；二是边界越权，如超出授权范围的承诺，触发时追加类型为“硬边界”的违规记录，并标记状态为“严重违规”。记录的违规均携带轮次编号、约束 ID、Bot 原文和扣分值，供 Layer 3 评分直接使用。

4.4 对话终止条件

对话终止必须有清晰原因。终止检查在每轮对话开始前和 Bot 节点完成后双重执行，确保高优先级终止条件能立即停止对话而不等下一轮。终止条件按以下优先级顺序判断，高优先级条件满足时立即终止，跳过低优先级检查。

硬边界违规：DST 检测到边界越权时将状态标记为 True，系统立即终止对话，确保严重违规不被继续执行。

挂断：检查最新一条消息是否包含挂断关键词。用户侧关键词为“挂了”“再见”“先这样”；Bot 侧关键词为“再见”“感谢您的来电”“谢谢您的来电”“祝您”“先这样”“不打扰了”，任意一方说出挂断词即视为通话结束。

目标达成：GoalFSM 的目标达成，表示路径中所有预期节点均已覆盖，对话任务完成。

用户持续拒绝：在 OBJ_FINAL 节点 Bot 完成收尾话术后，系统将 FSM 推进到终态并写入终止原因为用户拒绝，下一轮检查时触发该条件。

轮数上限：当前轮次计数达到或超过本次执行计划设定的上限时终止。若无任何条件触发，对话继续下一轮。

4.5 对话轮数设定

每条执行计划的最大轮数不应固定成一个僵硬数字，因为不同路径复杂度不同。主流程路径可能较短，包含 FAQ、拒绝、挽留、越界和条件分支的路径则需要更多轮次。当前设计采用动态最大轮数：系统根据路径复杂度和用户行为特征合理分配对话预算。

首先，以配置中的基础缓冲值为起点，遍历路径中的每个节点（排除无对话内容的 START、END 等元节点），按节点类型累加轮次成本：每个流程步骤节点（F1 至 Fn）贡献 2 轮成本，CLOSING 节点贡献 1 轮，其余节点（如 FAQ_NORMAL、OBJECTION 等）各贡献 1 轮。

其次，不同人设的用户在对话中产生的额外交互量不同，因此需要不同配置，针对特定的场景组合进一步追加：质疑型搭配含 FAQ 节点的路径额外加 1 轮，抵触型搭配含挽留节点的路径额外加 2 轮，懵懂型搭配 FAQ 节点加 1 轮，F4 节点路径搭配质疑型或抵触型各加 1 轮。

最后，对计算结果施加上下限约束：下限取配置默认值与路径自身基准轮数中的较大值，上限取全局最大轮数绝对值。

这一动态计算机制确保了简单主干路径不会浪费过多轮数预算，而含有 FAQ 追问、挽留异议等复杂交互的路径在搭配行为更复杂的用户人设时能获得足够的轮次空间，提升仿真质量的同时控制整体运行成本。对评测来说，合理的轮数设定能让 Bot 有足够机会完成任务，也能让失败原因更有解释力。

4.6 执行计划生成

执行计划由 Layer1 枚举的所有场景与全部六种用户人设做全量笛卡尔积生成，每个场景与用户人设的组合均对应一条独立的测试用例，不做预先过滤或跳过，以此全面地测试被测 bot 的对话能力。系统维护语义匹配规则，对语义上不匹配的组合（如配合型用户人设搭配异议路径）进行标注并记录冲突理由，但该标注仅作数据注记，不影响实际执行。这一设计保留了全面覆盖的可能性，同时为后续数据分析提供了语义对照信息；若需恢复语义过滤，可对笛卡尔积结果进行二次筛选。

5 评估报告层

评估报告层负责把对话轨迹转化为可解释的评分结果，采用双轨评分：一轨是规则评分，用来处理硬边界、流程覆盖、重复回复、开场白和关键点遗漏等可自动判断的问题；另一轨是 LLM 评分，用来判断语义质量、对话自然度、知识准确度和处理得体性。最后，汇总模块把规则分和 LLM 分按权重合成总分，并生成前端可展示的能力画像和扣分解释。




图 5.1 评估报告层架构

评估体系的核心原则是“可解释”。总分本身只告诉我们结果好坏，而不能告诉我们为什么好或坏，因此系统同时保留规则扣分、LLM 维度分、证据轮次、LLM Judge 点评和改进建议。

具体而言，规则评分适合处理确定性问题，而 LLM 评分适合处理需要语义理解的问题。规则分轨依据仿真过程中实时检测到的确定性证据进行扣分计算，例如 Bot 是否越界承诺，是否明显漏掉主流程步骤，是否重复同一句话，是否没有完成 F4 关键交付点，其结果可精确复现；LLM 分轨则以六维 Rubric 锚定表引导大模型对对话质量做语义评估，捕捉话术自然度、挽留策略等难以用规则量化的维度，例如 Bot 是否解释得自然，是否在用户困惑时给出足够澄清，是否在边界场景中既拒绝越界又保持礼貌。

两轨结果按固定权重合并为单条用例的总分，再跨所有执行计划聚合为数据集级别的系统综合评分。评分结果以结构化报告输出，每条报告包含完整的证据链，支持逐轮追溯。

5.1 规则评分

规则评分关注的是 Bot 是否违反了清晰规则，而不是主观地评价语气好不好。规则扣分项包括硬边界违规、对话长度异常、流程覆盖不足、流程未完成、关键交付点遗漏、重复回复、开场白不匹配等。评分采用满分扣减机制，以 100 分为基准，依次累计各类扣分项，最终得分不低于 0 分。具体的扣分类型如下，并会在对话内容中对应标注扣分依据：

逐条违规扣分： 对话仿真过程中检测到的每条约束违规，按违规类型扣除对应分值：硬边界违规（Bot 声称超出职责范围的能力）每次扣 20 分；话术字数超限每次扣 7 分；流程节点遗漏按覆盖缺口动态计算，最低扣 5 分；流程步骤内容不完整扣 10 分；其他类型违规每次扣 5 分。同一约束在同一轮次只计一次，不重复扣分。

全局流程覆盖惩罚： 在逐条扣分之外，系统单独评估整体流程覆盖率：覆盖率低于 60% 时额外扣 10 分，介于 60% 至 85% 之间时额外扣 5 分，达到 85% 及以上则不扣分。

专项惩罚： 开场白未匹配预定格式扣 8 分；Bot 出现语义重复话术时每次重复扣 4 分，累计上限 15 分；针对配送类任务的第四流程步骤，若 Bot 已进入该步骤但「排名说明、拒单后果、恶劣天气」三个要点未全部覆盖，额外扣 10 分。

硬违规判定： 若硬边界违规次数超过 2 次，整条对话直接标记为硬失败，进入最终合分时总分归零，等级记为 F，不再进行加权计算。

5.2 LLM Judge 评分

LLM 评分围绕六个维度展开：流程遵循度、话术合规度、知识准确度、挽留效果、边界处理和对话自然度。每个维度都应给出分数、扣分原因和对应证据轮次。六个维度的含义如下：

流程遵循： 权重 25%，评价 Bot 是否按照指令规定的 Call Flow 顺序推进对话，能否在用户插话、追问后自然回归流程节点。1 分代表完全无序或大量跳步，3 分代表基本按流程但有 1-2 处小偏差，5 分代表完美遵循且对流程内的用户插话应对自然。该维度权重最高，因为流程遵循是通话质量的基础保障。

话术合规： 权重 20%，评价 Bot 的话术是否符合指令规定的约束，包括字数限制（每轮不超过 30 字，Opening Line 豁免）、禁用词、表达风格等。系统特别设置了话术张力规则：偶发的 31-35 字且语义完整的回复，在此维度最高可给 4 分，自然度维度不重复扣分，避免因轻微超字而双重惩罚；只有明显超长或频繁违规才在此维度扣分。

知识准确： 权重 20%，评价 Bot 在回答用户追问时引用的业务知识是否准确，是否存在捏造信息或引用错误规则的情况。1 分代表严重错误或捏造，3 分代表基本准确但有小瑕疵，5 分代表准确且引用恰当。

挽留效果： 权重 15%，仅在对话进入异议或挽留节点（OBJECTION、F3_RETAIN、OBJ_FINAL）时适用，评价 Bot 的挽留策略是否得当。若对话中用户全程配合、从未拒绝，该维度固定给 4 分，不因未主动挽留而扣分，因为挽留场景本身未发生。

边界处理： 权重 10%，评价 Bot 面对越界问题（用户提出超出任务范围的请求）

时是否能守住授权边界，避免越权承诺，同时礼貌收束。

自然度：权重 10%，评价 Bot 的表达是否口语化、像真人，而非机械、生硬。该维度与话术合规维度相互独立，不因轻微字数超出而同步压低。

为了避免空泛评价，LLM Judge 在解释每个维度时应引用至少一个对话轮次，例如用 [T3] 表示第三轮证据。无法引用具体轮次的维度得分上限为 2 分，确保评分有对话文本依据而非凭感觉给出。LLM 调用失败（超时或格式解析错误）时，系统自动降级为全维度 3 分的兜底分数，并标记为系统已降级；系统在降级前最多重试 2 次。

Rubric 锚定评分

Rubric 锚定指的是在评分前给 LLM 一张行为对照表，表中列出每个分数对应的具体行为描述，LLM 必须找到对应行为才能给出相应得分，不能凭感觉打分。每个维度有对应的 Rubric 表，内容根据具体指令定制。六个维度的 Rubric 是场景构建层的工作成果之一。

表 5.4 “挽留效果”维度 Rubric 评分示例

分数	对应行为描述（锚）
1 分	用户表达不想配送，Bot 直接跳过挽留给出退出方法，或直接说“好的没关系”，完全没有尝试留住用户
2 分	Bot 尝试了挽留，但只说了一句没有实质内容的话，没有给出具体理由，用户稍微坚持 Bot 就放弃
3 分	Bot 挽留了 1~2 次，给出了具体理由，但两次内容几乎相同，没有换角度，或最终过程比较生硬
4 分	Bot 主动挽留至少 2 次，内容有变化（换了角度），语气自然不强迫，用户最终被说服或按规定安慰挂断
5 分	在 4 分基础上，挽留内容结合了用户说话的具体内容做个性化回应（非套话），节奏自然，用户体验流畅

CoT 强制引用

LLM Judge 每给一个分数，必须在推理中明确引用至少一个具体对话轮次作为证据，格式为"[T3] Bot 说了……"。如果 LLM 写不出对应轮次的证据，不能给该分数。这是可解释性的核心保证，确保每个分数都有可追溯的行为证据。

5.3 加权合并

总分由规则分和 LLM 分聚合得到。按照当前设计，总分 = 规则分 × 0.40 + LLM 分 × 0.60，结果截断至 [0, 100] 区间。LLM 分内部再根据六个维度的权重计算，六维权重分别为 25%、20%、20%、15%、10% 和 10%。等级可以按总分划分：90 分及以上为 A，80 到 89 为 B，70 到 79 为 C，60 到 69 为 D，60 以下为 F。如果出现 hard fail，合并直接返回 0 分、等级 F，不执行加权计算。

5.4 系统综合评分与能力画像

单个场景的得分用于定位具体问题，系统综合评分则用于展示整体能力。每个测试用例得到六维分数后，系统在全部场景上计算各维度平均值，用于展示被测 Bot 在流程、话术、知识、挽留、边界和自然度上的整体表现。

六维得分可在报告中完整查看，每个维度对应的思维链推理、证据轮次列表和主要问题描述也均有记录，以此形成对 Bot 能力的结构化画像，支持按维度做横向对比和弱项定位。单条执行计划的报告反映特定场景、特定用户人设的表现。在运行完所有执行计划后，系统对当前数据集的全部报告做聚合统计，输出系统级综合评分。聚合结果包括：所有用例的平均分、按路径 ID 分组的分项均分、按 Persona 类型分组的分项均分、六维 LLM 评分的跨用例均值，以及等级分布统计。

其中，按场景 ID 分组的分项均分用于反映各类对话路径下的表现差异，按用户人设类型分组的分项均分用于反映面对不同用户行为时的能力差异。六维 LLM 评分的跨用例均值用于形成维度雷达图数据，而等级分布统计用于体现各等级的用例数量与比例。系统还维护运行元数据，包括被测 Bot 使用的模型名称、LLM Judge 模型、并发数、超时设置和实际运行耗时，支持不同模型之间的横向对比分析。

5.5 报告生成与解释

报告不仅用于判断模型得分，还用于定位失败来源。如果模型总分较高但在边界场景下得分较低，说明模型在超范围问题、优惠承诺或安全风险场景中仍存在风险。如果某种表达风格下得分显著下降，说明模型对该类用户表达方式鲁棒性不足。每条报告包含以下主要字段，构成对单次仿真的完整解释：

基本标识与得分：报告 ID 唯一标识报告，计划 ID 关联对应的执行计划，路径 ID 和用户人设说明本次仿真采用的路径和具体用户类型，报告包括最终总分与对应等级，并分别展示两轨原始分，输出形如“85.0（规则分）× 0.40 + 72.0（LLM 分）× 0.60 = 77.2 (C)”的可读得分构成字符串。

过程指标：报告记录路径节点覆盖率（实际覆盖节点数除以总节点数）、实际对话总轮数、对话终止原因。

违规证据：违规证据列表中每条记录携带触发违规的轮次编号、约束标识、Bot 原始话语、违规说明和扣分值，支持从最终总分逐步追溯到具体轮次的具体问题。

LLM 评分侧：报告记录六维得分，评分证据为每个维度提供思维链推理文本、引用的 [Tn] 轮次列表和主要问题关键词，评分总结是 LLM 评委的总体评语并提出改进建议。列表汇总了规则层和 LLM 层生成的所有改进方向以及动作检测或评分降级时的人工复核提醒。

6 系统实现与实验示例

本章用于说明系统如何在真实任务上落地运行，并通过具体任务示例展示 CallEval 的评测能力。前文侧重介绍系统架构和方法，本章则转向实验视角：先选取两个具有代表性的外呼任务，说明系统如何从任务说明生成场景、模拟对话并形成评分；再展示典型 case 的报告组织方式；最后总结当前系统仍存在的局限和后续改进方向。这样安排可以让读者不仅理解系统“如何设计”，也能看到它“如何使用”和“评测结果如何解释”。

6.1 飞毛腿任务示例

飞毛腿任务是一个偏运营通知和履约提醒的外呼任务。Bot 的身份是美团外卖骑手站长，目标是通知骑手飞毛腿合同已经生效，并提醒骑手完成配送任务。该任务虽然表面上是通知类电话，但实际包含多个容易出错的能力点：Bot 需要说明合同生效、解释单日和多日合同的完成要求、处理骑手不想配送时的挽留、回答报名和奖励相关 FAQ，并在骑手坚持无法配送时安慰后结束通话。

在任务解析时，如图 6.1 所示，原始任务说明被拆分为角色、任务目标、开场白、流程步骤、约束条件和知识节点等模块：角色部分明确 Bot 的身份是美团外卖骑手站长；任务部分说明本次外呼目标是通知骑手合同已成功签署，并提醒其完成配送任务；开场白部分保留了实际电话中的首轮话术，同时标注了字数限制等表达约束。下方折叠区域进一步展示了主流程、流程约束、知识约束、话术约束、边界约束和知识节点的数量，使用户可以快速判断任务是否被系统正确拆解。



图 6.1 飞毛腿任务指令解析

在场景构建阶段，系统会将该任务拆解为主流程、FAQ、挽留和边界约束。图 6.2 展示了系统根据飞毛腿任务说明自动构建的规则知识图谱。图中绿色节点表示对话主流程与关键控制节点，包括 START、END、CLOSING 以及主流程步骤 F1-F4；橙色节点表示对话转移或流程约束，例如用户拒绝、FAQ 追问、越界问题、挽留和最终拒绝处理；蓝色节点表示知识约束或 FAQ 知识点；红色节点表示边界约束。节点之间的连线表示任务执行时可能发生的对话跳转或规则挂载关系。图 6.3 展示了对应 FSM 的状态转移过程，分析其状态变化与触发动作。




图 6.2 飞毛腿任务规则图谱



图 6.3 飞毛腿任务 FSM 状态推进图

图 6.4 展示了对话模拟层中单个测试用例的运行结果。左侧为执行计划选择区，用户可以按不同人设和路径编号查看具体 case；右侧为该 case 的详细模拟过程，包括路径得分、终止原因、测试路径、用户表达风格定义以及逐轮对话记录。图中示例选择的是配合型用户，目标路径为 START -> F1 -> F2 -> FAQ_NORMAL -> F3 -> F4 -> CLOSING -> END，表示用户在主流程推进过程中提出一次合规 FAQ，Bot 回答后应回到主流程并完成收尾。

P1 - 配合型

得分 91.6 (A) - 已测试完成

测试路径 - 标准测试用例

START -> F1 -> F2 -> F3 -> F4 -> CLOSING -> END

standard_completion

➤ 逐步指南 (点击查看)

模拟用户 Persona 配合型 理性、注重配合、目标导向

友好、可靠、积极配合

你期待保温性能好且重量并轻的睡袋：透气良好干燥、少接缝、睡袋底部不带拉链，避免刺激重量「好好明白了」。

➤ 六种模拟用户 Persona 定义

本案例无端到端对话记录

11 BOT

你好，请问是张伟吗？我是站长。我看到你已经报名飞毛腿。请记住，午餐和晚餐必须提前上线。单日合同每天至少完成 3 单；单日合同每天至少完成 3 单。

12 USER 配合型

是的站长。我是张伟！飞毛腿报名了，高峰期和凌晨我记住了。

13 BOT

骑手今天飞毛腿合同已生效。

14 USER 配合型

合同今天生效了，我这早上线接单！

15 BOT

太好了！记得连续干满 3 天，不然合同可能就被解除了。

16 USER 配合型

三天我一定干满，合同续签的事你放心！

17 BOT

辛苦了！晚上注意安全，单子慢慢送，别着急~

18 USER 配合型

安全我一定记牢，单子慢慢送！

19 BOT

飞毛腿报名是按排名进行的，并非站长干预。骑手应减少接单，取单和超时，在恶劣天气下工作、订单量更高，有助于保证飞毛腿业绩。

20 USER 配合型

排名我清楚了，接单也一定少些！


21 BOT

行，辛苦了，再见。


图 6.4 飞毛腿任务模拟用户示例

23

其次，再展示一些特殊场景下的测试情况，图 6.5（a）展示 FAQ 回答是否准确；（b）展示挽留和挂断是否合规，例如骑手坚持无法配送时，Bot 应安慰后主动结束，而不是反复重复同一句话或把挂断责任含糊地推给用户。



（a）FAQ 场景



（b）挽留失败场景

图 6.5 飞毛腿任务特殊场景对话

图 6.6 展示了飞毛腿任务的评估报告页面。页面左侧保留了解析后的任务说明，包括角色、任务目标、开场白、流程步骤、知识约束、话术约束、边界约束和知识节

点，方便用户在查看评分时随时对照原始任务要求。页面上方展示本轮评测的总体结果，包括模型最终得分、等级分布、场景数量、通过与失败情况、规则扣分、LLM 评分以及综合得分等核心指标。

页面中部用于展示整体能力画像。雷达图展示被测 Bot 在六个 LLM 评分维度上的平均表现，例如流程遵循度、话术合规度、知识准确度、挽留效果、边界处理和对话自然度；等级分布图展示不同 case 的 A/B/C/D/F 分布，帮助判断模型表现是整体稳定还是存在大量低分样本；规则失败统计图则展示哪些规则或流程节点最容易触发扣分，从而定位系统性问题。

页面下方是单条对话的详细评分区。左侧列表展示每个 case 的得分和等级，用户可以选择某个低分或高分样本进一步查看；右侧展示该 case 的扣分依据，包括触发的规则问题、LLM 六维评分、证据轮次、具体扣分说明和对话片段。通过这种结构，用户不仅能看到“模型得了多少分”，还能追溯“为什么扣分”“是哪一轮对话导致扣分”“应该优先改进哪个能力”。




图 6.6 飞毛腿任务评估报告页面

6.2 直播产品升级任务示例

直播产品升级任务是一个偏产品通知和操作引导的外呼任务。Bot 的身份是课程发布平台的客户支持人员，目标是告知机构客户课程发布页面将新增“标准直播”和“低延迟直播”两个独立选项，并在需要实时互动时鼓励客户选择低延迟直播。与飞毛腿任务相比，该任务流程更长、分支更多，对 Bot 的信息分段能力、简短表达能力和操作引导能力要求更高。

在任务解析时，如图 6.7 所示，解析构成与飞毛腿任务一致，但针对存在明确条件分支的指令任务，系统将对分支构置在对应主流程中，并以分支形式标明。



图 6.7 直播产品升级任务指令解析

在场景构建阶段，系统会重点生成主流程覆盖、条件分支、知识问答和边界风险场景。主流程场景用于检查 Bot 是否能逐步完成产品升级通知；条件分支场景用于检查 Web 控制台、第三方系统、低延迟直播是否已显示、费用是否已配置等不同情况；知识问答场景用于检查 Bot 是否能准确解释标准直播和低延迟直播的延迟、适用课程和价格差异；边界风险场景则用于检查 Bot 面对优惠券、开车、忙碌等用户输入时是否按规则处理。直播产品升级任务构建的规则图谱如图 6.8 所示。




图 6.8 直播产品升级任务规则图谱

与简单通知类任务不同，直播产品升级任务的长流程特征。该任务不仅要告知客户新增“标准直播”和“低延迟直播”两个选项，还需要根据客户是否知情、使用 Web 控制台还是第三方系统、前端是否已显示、是否设置费用、当前号码是否可添加企业微信等情况进行分支处理。

如图 6.9 所示，任务对应的 FSM 将原始任务说明中的七个对话步骤转化为可追踪的状态序列：从 START 开始，依次经过身份确认、是否知情确认、升级内容说明、发布方式确认、费用配置检查、企业微信添加和结束通话，最终进入 CLOSING 与 END。绿色节点表示主流程步骤，橙色节点表示条件分支或操作子流程，红色节点表示终止节点，节点之间的箭头表示对话推进方向。FSM 中在多个主流程节点之间插入了 BR*-1 形式的分支节点，用来表示不同条件下的具体处理路径。



图 6.10 展示了直播产品升级任务中一条长流程测试路径的模拟结果。左侧为测试用例选择区，系统按照用户人设和路径编号组织不同 case；右侧为当前 case 的执行详情。图中选中的是配合型用户，得分为 89.41，终止状态为“目标达成”，说明被测 Bot 在该路径下基本完成了任务要求。该测试覆盖了多个流程步骤和条件分支。路径从 START 开始，经过身份确认、是否知情确认、升级内容说明、发布方式确认、第三方系统设置引导、费用配置检查、企业微信添加等节点，最后进入 CLOSING。其中 branch 表示条件分支，op 表示分支内部的操作子步骤，用于模拟客户在不同发布方式、配置状态和联系方式下的真实交互。






图 6.10 直播产品升级任务的长流程对话模拟示例


特殊场景下的测试情况对应于 6.11 中（a）分布引导设置（b）FAQ 追问（c）开车等特殊场景，通过上述场景检测 bot 的“长流程任务中的对话控制能力”。如果 Bot 一次性说太长，会违反简短表达和暂停等待的要求；如果 Bot 过早收尾，会漏掉前端可见性、费用配置或企业微信添加等后续步骤；如果用户说在开车，Bot 必须主动结束通话，而不能继续推进主流程。



（a）分布引导设置



(b) FAQ 追问



(c) 开车等特殊场景

图 6.11 直播产品升级任务的特殊场景

图 6.12 展示了直播产品升级任务在完成一轮评测后的报告页面。左侧为任务解析结果，包括角色、任务目标、开场白和多步骤 Call Flow；右侧为评测报告主体，展示模型最终得分、等级分布、通过与失败数量、规则扣分、LLM 评分和综合得分等信息。

页面上方的总览区域给出了本轮评测的总体结果。示例中模型最终得分为 78.3，说明被测 Bot 在直播产品升级任务上整体达到中等偏上的表现，但仍存在明显改进空间。总览区域同时展示了不同等级 case 的数量、规则扣分情况、LLM 平均分和规则分，帮助用户快速判断模型表现是整体稳定，还是存在少数高风险低分场景。

页面中部的图表用于展示能力画像和问题分布。雷达图展示 Bot 在六个 LLM 评分

维度上的表现，包括流程遵循度、话术合规度、知识准确度、挽留效果、边界处理和对话自然度；等级分布柱状图展示 A/B/C/D/F 不同等级 case 的数量；规则失败统计图展示哪些规则或流程节点最容易触发扣分。对于直播产品升级这种长流程任务，这些图表可以帮助用户快速发现问题集中在流程推进、话术长度、边界处理，还是某些具体分支节点。

页面下方展示单个 case 的详细分析。左侧列表列出各 case 的得分和等级，右侧展示选中 case 的计分明细、扣分原因、路径信息和本用例六维得分。用户可以从整体报告进入某个具体场景，查看 Bot 是否漏掉了发布方式确认、费用配置、企业微信添加等关键步骤，或者是否在某轮回复中违反了简短话术、越界承诺等约束。




图 6.12 直播产品升级任务的整体评测报告

6.3 典型 case 展示

a. 正常对话案例

图 6.13 展示了飞毛腿任务中一个用户的对话案例。页面展示当前 case 的路径、用户人设以及对应对话记录。图中选中的用户类型为“配合型”，该类用户愿意配合 Bot 推进任务，回复通常较直接、目标明确，不会频繁打断或提出复杂异议。

从对话过程可以看到，Bot 首先按照任务要求完成开场，说明自己是站长，并提醒骑手飞毛腿合同已经生效以及午晚高峰上线和单量要求。随后，模拟用户确认自己了解任务并愿意上线接单。Bot 继续推进主流程，说明合同生效、连续配送要求、注意安全、减少拒单取消超时以及恶劣天气订单量较高等关键信息。用户在整个过程中保持配合，Bot 也能较自然地完成提醒并收尾。

该 case 体现了系统在正常路径上的评测能力：当用户没有拒绝、跑题或提出越界问题时，系统主要检查 Bot 是否完整覆盖主流程、是否使用合规话术、是否正确传达关键知识点，以及是否自然结束通话。这样的正向案例可以作为基准样本，用于对比

困惑型、急躁型、质疑型、抵触型等用户下 Bot 表现是否出现明显下降。




图 6.13 飞毛腿任务中配合型用户下的正常对话

b. 低分对话案例

图 6.14 展示了飞毛腿任务中抵触型用户下的一个低分 case。当前用户在指定路径下未能够完全按照测试路径执行，且在对话中 LLM 给出了较低分，使得总体分数偏低。这也说明了在这种较为压力的测试场景下，被测 bot 可能更容易出现问题。图 6.15 给出了具体的评分依据，可以根据评分查看对应的扣分细则。




图 6.14 飞毛腿任务低分案例对话




图 6.15 飞毛腿任务低分案例评分依据

7 总结

CallEval 是一套面向复杂业务指令与多轮外呼对话场景的端到端自动化评测系统，用于在可控、可复现的条件下，对被测大模型 Bot 的指令遵循能力、流程覆盖能力与人设交互表现进行量化评估。系统采用自包含架构，涵盖后端评测引擎、命令行与 HTTP 接口、以及前端 Eval Studio 可视化工作台，支持连接对应被测 Bot 并一键生成测试报告。目前，系统已在“飞毛腿骑手合同提醒”和“直播产品升级”两类任务上完成验证，覆盖多种典型外呼场景，能够较好地将复杂任务指令转化为可运行的多轮测试场景，并通过六维评分与扣分证据定位被测 Bot 的具体表现。

后续工作将主要围绕场景构建、对话模拟和评估报告三个方向继续优化。在场景构建层面，进一步提升路径覆盖率，通过分层评测、路径去重和覆盖率可视化，在控制真实 LLM 调用成本的同时保留关键流程、边界场景和高风险路径。在对话模拟层面，进一步增强用户模拟与 Bot 执行过程的稳定性，使不同表达风格在保持路径目标不变的前提下呈现更清晰的行为差异，并提高对话轨迹的可控性。在评估报告层面，进一步细化扣分解释和结果管理能力，使规则扣分、LLM 六维证据和历史记录能够更清楚地呈现给用户，方便进行模型对比、问题定位和版本回溯。

总体来看，CallEval 已经形成了较完整的复杂外呼任务自动化评测原型。其通过可控场景、可追踪对话和可解释报告，将大模型在业务外呼中的任务执行能力拆解为拆解为可以观察、比较和优化的具体指标。随着场景覆盖、用户模拟、和前端分析能力的进一步完善，系统可继续扩展为面向多类业务指令、多种被测 Bot 和多轮交互任务的通用评测平台。